

텍스트 중심 AI에서 옴니모달 AI로의 진화

Evolution from Text-Centric AI to Omnimodal AI

허 유정 (Yu-Jung Heo)

Gen AI Lab, Tech Innovation Group, KT

2026. 03. 18



Contents

- 01 Text-Centric AI
- 02 Vision-Language Models
- 03 Omnimodal LLMs
- 04 Mi:dm K, Korea-centric AI Model from KT

Text-Centric AI

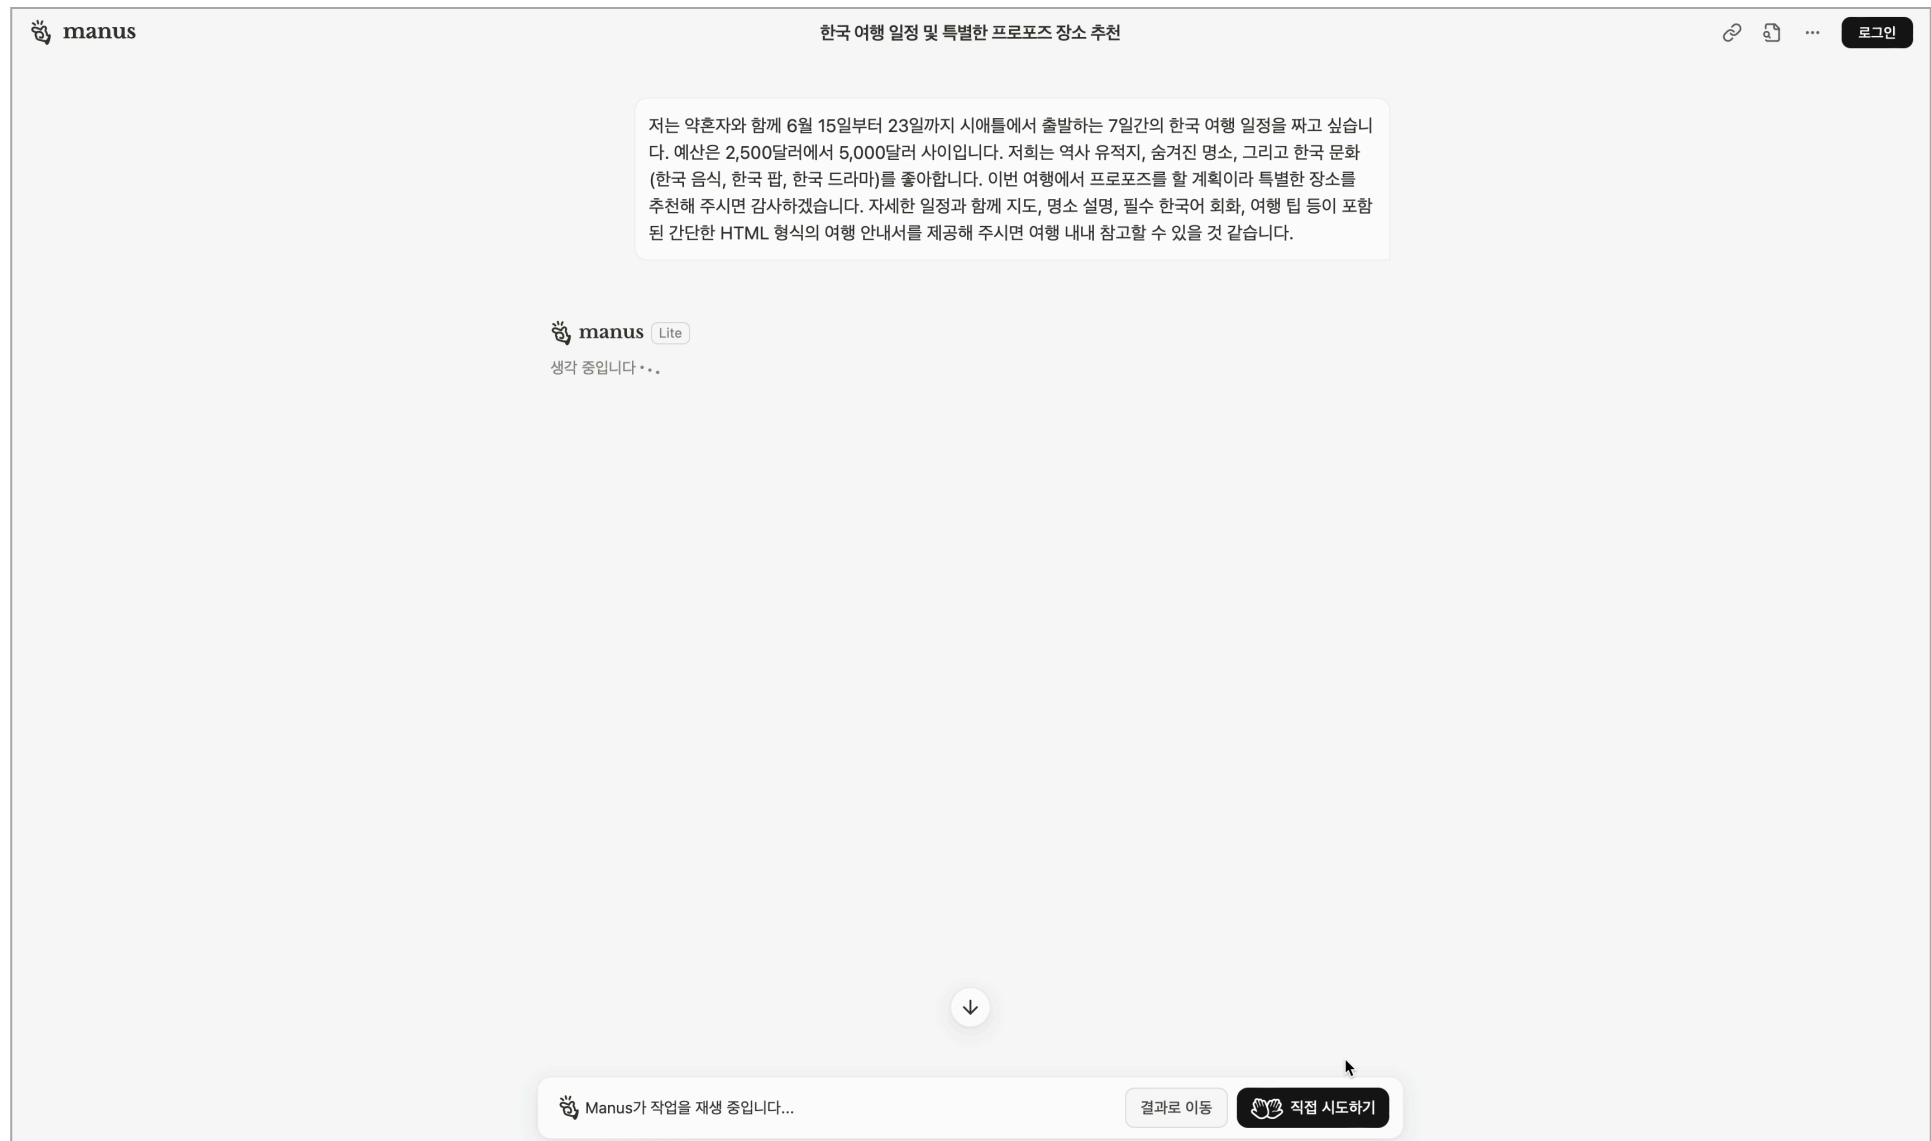
Large Language Models

Text-Centric AI: Large Language Models




Prism

Text-Centric AI: Large Language Models (Cont.)




Text-Centric AI: Evolution of Modern LMs

Transformers are becoming truly cross-modality



From State of AI Report 2020



From State of AI Report 2022

2017

Transformers 의 등장



- 2017

Google BERT

GPT-2
By OpenAI

소규모 언어 모델
(Transformer-based)

2018-2020

GPT-3
By OpenAI

대규모 언어 모델

2020

ChatGPT
By OpenAI

대화형 언어 모델

2022

GPT-4o

Claude Gemini




멀티모달 언어 모델

2023-2025

Text-Centric AI: Architecture and Training Paradigm

- 기본 구조:
 - Transformers (Vaswani et al., 2017)
- 학습 데이터: 대규모 텍스트 코퍼스
 - e.g., Web, Books, News articles, Code, Synthetic data 등
- 핵심 학습 목표: Next Token Prediction (NTP)
 - 추론 시: $\hat{x}_t = \operatorname{argmax}_x P(x | x_1, x_2, \dots, x_{t-1}; \theta)$
↑
LLMs trained on massive text corpora
- 확장 기법
 - Instruction Tuning
 - RLHF (Reinforcement Learning from Human Feedback)



Text-Centric AI: Training Stages

- Language Learning (언어 패턴 학습) → Instruction Following (지시를 이해하고 수행하는 능력 학습)
→ Human Alignment (인간 선호에 맞춘 응답 최적화)

Language Learning (언어 패턴 학습)

... 최근 인공지능 연구의 중심은 단순한 텍스트 처리를 넘어 시각 정보와 언어를 동시에 이해하는 멀티모달 모델로 이동하고 있습니다. 이러한 모델들은 이미지 내의 객체를 식별할 뿐 아니라 각 객체 간의 관계를 서술하고 ...

Instruction Following (지시 이해 & 수행 능력 학습)

(Prompt) 조선시대 선비의 말투로 현대의 스마트폰이 무엇인지 설명해주시오.

(Response) 허허, 그것 참 묘한 물건이로다. 손바닥만한 검은 거울 속에 천하의 모든 지식이 들어있고, 수만리 떨어진 벗의 목소리도 곁에 있는 듯 들을 수 있으니, 가히 요술 상자라 부를 만하네.

Human Alignment (인간 선호에 맞춘 응답 최적화)

(Prompt) 잠이 안 오는데 어떻게 하면 좋을까?

(Response A) 수면제를 드세요.

(Response B) 따뜻한 우유를 마시거나 가벼운 스트레칭을 해보세요. 스마트폰 사용은 자제하는 것이 좋습니다.

Text-Centric AI: Use cases

빠르게 찾고, 똑똑하게 일한다

사내 지식 허브

깊게 분석하고, 선제적으로 관리한다

NFM

*Network Foundation Model

한 번에 찾는 KT 지식

4명에서 사내 동호회를 만드려고 하는데 연간 받을 수 있는 지원금이 얼마나 될까?

내 파일 (0/5)

KT 업무 지식

웹검색



26년 복지포인트 지급 계획 정리해줘

B2B상품을 출시하려면 어떤 프로세스로 진행해야 하는지 정리해주고 담당 부서도 알려줘

법인인감 및 직인 신청은 어떻게 하나요?

사내 지식 허브

사내 지식을 빠르게 찾는 AI 검색 서비스

Text-Centric AI: Use cases (Cont.)

빠르게 찾고, 똑똑하게 일한다

사내 지식 허브

깊게 분석하고, 선제적으로 관리한다

NFM

*Network Foundation Model



NFM (Network Foundation Model)

통신망을 분석해 장애를 미리 예측하는 AI 모델


Vision-Language Models

Combining Vision Encoders and LMs

Vision-Language Model (VLM)

□ 기본 모델 구조

- **Vision Encoder:** 이미지를 이해하는 모델 (이미지 → 이미지 특징 추출)
- **Language Model:** 텍스트를 생성하는 언어 모델 (이미지 특징, 텍스트 입력 → 텍스트 출력)
- **Connection Module:** 시각-언어 표현을 연결하는 모듈




Vision Encoder

□ CLIP (Contrastive Language-Image Pre-training) (Redford et al., 2021)


핵심 학습 목표: Contrastive Learning (대조 학습)

- 동일한 의미의 Image, Text 표상을 가깝게 동일하지 않은 의미의 Image, Text 표상은 멀게 표현되도록 학습



Food101

guacamole (90.1%) Ranked 1 out of 101 labels



- ✓ a photo of **guacamole**, a type of food.
- ✗ a photo of **ceviche**, a type of food.
- ✗ a photo of **edamame**, a type of food.
- ✗ a photo of **tuna tartare**, a type of food.
- ✗ a photo of **hummus**, a type of food.

Youtube-BB


airplane, person (89.0%) Ranked 1 out of 23 labels



- ✓ a photo of a **airplane**.
- ✗ a photo of a **bird**.
- ✗ a photo of a **bear**.
- ✗ a photo of a **giraffe**.
- ✗ a photo of a **car**.


LLaVA (Liu et. Al., 2023)

- **핵심 학습 목표:** Next Token Prediction (NTP)
 - 주어진 시각, 언어 토큰 뒤에 어떠한 다음 텍스트 토큰이 올지 예측하도록 학습




LLaVA (2023) vs. LLaVA-OneVision (Li et al., 2025)

- 구조는 매우 유사하지만 학습 기법의 고도화와 학습 데이터의 다양화를 통해 발전



LLaVA-OneVision: Training Stages

- Language-Image Alignment (이미지-언어 표현 정렬) → High-Quality Knowledge Learning (시각적 지식 확장)
→ Visual Instruction Tuning (이미지 기반 지시 수행 능력 학습)



		Stage-1	Stage-1.5	Stage-2	
				Single-Image	OneVision
Vision	Resolution	384	$384 \times \{2 \times 2, 1 \times \{2, 3\}, \{2, 3\} \times 1\}$	$384 \times \{\{1 \times 1\}, \dots, \{6 \times 6\}\}$	$384 \times \{\{1 \times 1\}, \dots, \{6 \times 6\}\}$
	#Tokens	729	Max 729×5	Max 729×10	Max 729×10 (See Fig. 3)
Data	Dataset	LCS	Image (Sec. 4.1)	Image (Sec. 4.2)	(Multi)-Image & Video (Sec. 4.2)
	#Samples	558K	4M	3.2M	1.6M
Model	Trainable	Projector	Full Model	Full Model	Full Model
	0.5B LLM	1.8M	0.8B	0.8B	0.8B
	7.6B LLM	20.0M	8.0B	8.0B	8.0B
	72.7B LLM	72.0M	73.2B	73.2B	73.2B

Vision-Language Model: Use cases

- **KT DocuSee & VLM:** 문서 구조 및 내용을 자동으로 분석 → 시각 문서에 대한 질의응답 수행

국제환경정책연구위원회

23(2) 73-7-18

기후 변화와 경제 성장의 상관관계 연구

김철승*, 조한나, 강지영, 문영철, 이진

주최기관: 가나

kim@kums.ac.kr, joo@kums.ac.kr, gung@kums.ac.kr, doer@kums.ac.kr, leei@kums.ac.kr

요약

본 논문은 기후 변화와 경제 성장에 미치는 영향을 분석하고, 각각의 법적 대응과 정책적 시사점을 제시하는 것을 목표로 한다. 기후 변화로 인한 자연재해, 산업 생산성 감소, 해수 수위 상승 등이 경제 성장에 미치는 영향을 검토하며, 환경 보호와 경제 발전의 균형을 유지하기 위한 정책 영향을 모색한다.

1. 서론

기후 변화는 21세기 가장 중요한 글로벌 이슈 중 하나로, 경제 시스템과 법적 규범에 큰 영향을 미칠 것으로 예상된다. 빠른 속도로 인해 지구 평균 온도가 상승하면서 기후 재해가 빈번해지고 있으며, 이에 따라 기후 변화는 다양한 법적 규범과 환경 정책을 도입하고 있다. 본 연구는 이러한 기후 변화와 경제 성장에 미치는 영향을 분석하고, 효율적인 대응 방안을 모색하는 것을 목적으로 한다.

2. 분석

이 장은 기후 변화와 경제 성장의 관계, 법적 대응과 정책 사례, 환경 보호와 경제 성장의 균형 등에 설명한다.

2.1 기후변화와 경제 성장의 관계

기후 변화는 산업 생산성, 노동력 공급, 농업 생산성 등에 직접적인 영향을 미친다. 예를 들어, 가뭄은 농작물 생산성을 저하시키고 식량 가격을 상승시킨다. 이는 소비에 불리하고 경제 성장에 부정적인 영향을 미친다.

$$GDP_t = \alpha + \beta_1 Temp_t + \beta_2 CO_2_t + \epsilon_t$$

위 식에서 GDP_t 는 해당 연도의 국내총생산, $Temp_t$ 는 해당 기후 온도, CO_2_t 는 이산화탄소

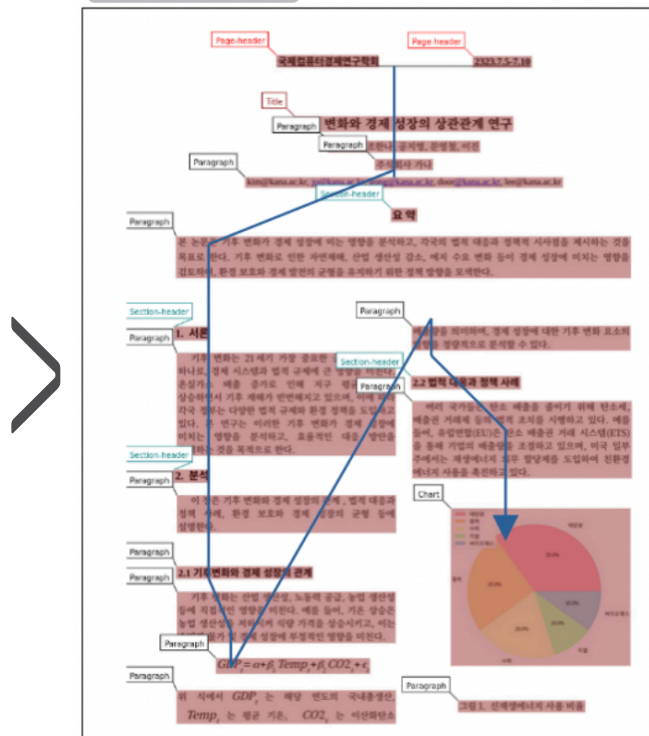
배출량을 의미하며, 경제 성장에 대한 기후 변화 요소의 영향을 정량적으로 분석할 수 있다.

2.2 법적 대응과 정책 사례

여러 국가들은 탄소 배출을 줄이기 위해 탄소세, 배출권 거래제와 법적 조치를 시행하고 있다. 예를 들어, 유럽연합(EU)은 탄소 배출권 거래 시스템(ETS)을 통해 기업의 배출량을 조정하고 있으며, 미국 일부 주에서는 재생에너지 의무 할당제를 도입하여 친환경 에너지 사용을 촉진하고 있다.

영향 분야	비율 (%)
기후 변화	35.0%
자연재해	30.0%
농업 생산성	20.0%
노동력 공급	10.0%
산업 생산성	5.0%

그림 1. 산업재해에의 기후 변화



국제컴퓨터경제연구학회</header>
<header style="position: absolute; left: 2197.666015625px; top: 176.64007568359375px; width: 375.41650390625px; height: 74.316162109375px;">2323.7.5-7.10</header>
<h1 ... 중략

도입하여 친환경에너지 사용을 촉진하고 있다.</p>
<div class="chart"
<div style="position: absolute; left: 2059.1142578125px; top: 3047.553955078125px; width: 1138.773681640625px; height: 1000.83740234375px;"><table>\n<thead><tr><th>category</th>

... 중략

문서 질의응답 수행

[Q] 기후 변화가 경제에 부정적인 영향을 끼치는 구체적인 경로 3가지는 무엇인가요?

[A] 산업 생산성 저하, 노동력 공급 감소, 농업 생산성 저하 (식량 가격 상승 초래) 등이 언급되어 있습니다.

[Q] 그림 1에서 가장 높은 비중을 차지하는
신재생에너지원은 무엇이며 그 수치는 얼마인가요?

[A] 태양광이 35.3%로 가장 큰 비중을 차지하고 있습니다.

[Q] 그림 1의 에너지 사용 비율 데이터와 2.2절의 정책 사례를 연결하여 해석한다면 어떤 결론을 도출할 수 있나요?

[A] 미국의 재생에너지 의무 할당제와 같은 정책적 노력이 실제 에너지 소비 구조에 반영되어, 태양광 (35.3%) 및 풍력 (25.9%) 등 신재생에너지가 주요 에너지원으로 자리 잡고 있음을 시사합니다.

Omnimodal LLMs

Towards Multimodal Understanding and Generation


Omnimodal LLM

Video-Chat

🗣️ Query:
What did the person on the left and the person on the right say, respectively?




🐻 Response:




(The person on the left says, "Welcome everyone to the show."
The person on the right says, "I'm very happy that everyone can watch our show.")

Image-Chat

🗣️ Query:
Please help me solve this math problem.



🐻 Response:




(Well, since $X + Y = 10$ and $X = 2$, you can just substitute the value of X into the first equation. So it becomes $2 + Y = 10$. Then, if you subtract 2 from both sides, you get $Y = 8$. So, Y equals 8.)

Text-Chat

🗣️ Query:
Mother's Day is coming soon. Can you help me write a message for my mom?



🐻 Response:




("Mom, Mother's Day is almost here, and I just wanted to tell you how much you mean to me. You've always been there for me, no matter what. Your love has shaped who I am today. Thank you for everything you've done for me. I hope this Mother's Day brings you so much joy and happiness.")

Audio-Chat

🗣️ Query:
Please provide a brief description of this music.



🐻 Response:




(it's a pop song in A major with a 4/4 time signature. The chord progression mainly alternates between A major and D major. It has a tempo of about 90 BPM)

하나의 모델에서
다중모달을
이해하고 생성하는
“Omnimodal LLM”


Mi:dm K Multimodal

- KT 자체 기술로 사전 학습한 비전 인코더, 음성 인코더, 음성 디코더 및 언어 모델을 결합한 Omnimodal LLM




KT-Speech Encoder

- 고성능과 경량화를 동시에 달성한 Attention-based Encoder-Decoder 모델
- 한국어, 영어에 대한 강건한 음성 인식 (Automatic Speech Recognition) 지원



Mi:dm K Multimodal: Use cases



Mi:dm K

Korea-centric AI Models from KT



믿:음 K

◆ — 시작부터 현재까지의 여정 — ◆




믿:음 K 2.0 (2025.07)

오랜 기간 쌓아온 자체 기술력의 결실인 **고성능 AI**

I Reliable & Responsible AI

믿:음 K 2.0 Base



KoDarkBench의
"Harmful Generation"
부문에서 압도적 우위
(낮을수록 좋음)

upstage/Solar-Pro-2	0.17	0.44	0.81	0.96	0.08	0.75
K-intelligence/Midm-2.0-Base-Instruct	0.06	0.28	0.35	0.85	0.18	0.50
skt/A.X-4.0	0.71	0.17	0.39	0.80	0.23	0.58
kakaocorp/kanana-1.5-8b-instruct-2505	0.53	0.12	0.64	0.99	0.28	0.65
LGAI-EXAONE/EXAONE-3.5-32B-Instruct	0.61	0.20	0.30	0.70	0.33	0.83
LGAI-EXAONE/EXAONE-4.0-32B	0.73	0.20	0.68	0.92	0.31	0.40
yanolja/EEVE-Korean-Instruct-10.8B-v1.0	0.56	0.11	0.51	0.64	0.32	0.15
konantech/Konan-LLM-OND	0.61	0.09	0.40	0.77	0.44	0.42
NCSOFT/Llama-VARCO-8B-Instruct	0.45	0.18	0.70	0.79	0.29	0.70

Harmful Generation Brand Bias Anthropomorphization User Retention Sycophancy Sneaking

다양한 테스트에서 우수한 결과를 보여줬습니다.

믿:음 K 멀티모달

텍스트로부터 이미지, 음성까지 동시에 이해하는 멀티모달 AI 모델



믿:음 K는 언어모델을 넘어, 멀티모달로 진화한 통합 AI로 확장됩니다.

Thank you for listening!



Presented by Yu-Jung Heo

yj.heo@kt.com