

SIEM 솔루션에서 ML 활용 방안 (Splunk)

Cisco 총판 에티버스
박용 Ph.D.

splunk>




아젠다

- 데이터 플랫폼 (Splunk)
- Confusion Matrix 기반의 보안 평가 및 분석
- FP (False Positive, 오탐) 발생 원인 & 방지 방안
- FN (False Negative, 미탐) 발생 원인
- FP (False Positive, 오탐) & FN (False Negative, 미탐) 방지 방안
- Splunk AI 에 대해서
- Splunk AI Assistant (생성형 AI)
- Customizable ML (Outlier, Liner Regression, Clustering)


데이터 수집

다양한 데이터 소스로부터 제약 없는 수집 (agent, agentless 수집 가능)




데이터 관리 (DMX – Data Management Experience)

통합된 데이터 구성, 처리 및 관리



데이터 처리



데이터 검색 & 분석

강력한 검색 기능 (SPL)

- SQL과 Unix 파이프라인 구문이 결합된 최적의 검색 언어 제공 → **SPL (Search Processing Language)**
- 검색, 상호 연관, 분석 및 시각화 관련된 150개 이상의 명령어 제공
- 통계, 그래프, 각종 연산 함수를 활용한 분석
- 별도의 추가적인 설정 없이 상관 관계 분석
- 신속하게 필요한 데이터를 찾아 분석하여 사고 근본 원인 파악

The screenshot displays the Splunk Search & Reporting interface. At the top, the search bar contains the query `Index*_internal`, which is highlighted with a yellow box and labeled "검색어" (Search term). Below the search bar, a timeline visualization shows the distribution of events over time, labeled "시계열 데이터 분포" (Time series data distribution). The main results pane shows a table of events, with the first few rows highlighted by a yellow box and labeled "검색 데이터" (Search data). The table columns include Time, Event, and various fields related to the search process. On the left side, the "Selected Fields" list is visible, with a yellow box labeled "자동 필드 추출" (Automatic field extraction) pointing to the list.


Time	Event
7/28/20 12:24:50.822 AM	07-28-2020 00:24:50.822 +0000 INFO PeriodicHealthReporter - feature="Searches Skipped" color=green due_to_stanza="feature:searches_skipped" node_type=feature node_path=splunkd.search_scheduler.searches_skipped
7/28/20 12:24:50.822 AM	07-28-2020 00:24:50.822 +0000 INFO PeriodicHealthReporter - feature="Searches Delayed" color=green due_to_stanza="feature:searches_delayed" node_type=feature node_path=splunkd.search_scheduler.searches_delayed
7/28/20 12:24:50.822 AM	07-28-2020 00:24:50.822 +0000 INFO PeriodicHealthReporter - feature="Search Lag" color=green due_to_stanza="feature:search_lag" node_type=feature node_path=splunkd.search_scheduler.search_lag

Confusion Matrix 기반의 보안 평가 및 분석

Confusion matrix는 모델의 성능을 평가할 때 사용하는 표 형식의 도구입니다. 실제 값(실제 공격/정상 여부)과 예측 값(모델의 판단)을 비교해, 각 경우별 예측 결과를 상세하게 확인할 수 있습니다

Confusion Matrix

- T(True): 예측한 것이 **정답**
- F(False): 예측한 것이 **오답**
- P(Positive): 모델이 **positive**(비정상, 아노말리)라고 **예측**
- N(Negative): 모델이 **negative**(정상)라고 **예측**
- **TP**: 실제 값이 positive인데, positive로 예측. ex) 스팸 메일을 스팸 메일로 분류
- **TN**: 실제 값이 negative 인데, negative로 예측. ex) 스팸 메일이 아닌 일반 메일을 일반 메일로 분류
- **FP**: 실제 값이 negative인데, positive로 예측. ex) 일반 메일인데 스팸 메일로 분류
- **FN**: 실제 값이 positive인데, negative로 예측. ex) 스팸 메일인데 일반 메일로 분류



N=100	Actual: Yes(Positive)	Actual: No(Negative)	
Predicted: Yes(Positive)	TP: 24	FP: 3 오탐	$24/24+3=0.89$
Predicted: No(Negative)	FN: 8 미탐	TN: 65	$65/8+65=0.89$
$3+8/24+8+3+65=0.11$	$24/24+8=0.75$	$65/3+65=0.96$	$24+65/24+8+3+65=0.89$

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- 데이터 품질 문제
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. 탐지 룰의 미세 조정 부족:

- 탐지 룰들은 일반적인 위협을 탐지하도록 설계되었지만, 특정 조직의 네트워크 환경과 비즈니스 로직을 충분히 고려하지 않습니다
- 고객사 환경 맞게 조정되지 않은 탐지 룰을 활성화하면 해당 환경에 맞지 않는 많은 오탐이 발생할 수 있습니다
 - "모든 원격 로그인 시도"를 비정상으로 탐지하는 룰은 재택근무가 일상화된 환경에서 엄청난 수의 오탐을 유발

2. 너무 낮은 또는 고정 임계값 설정:

- 특정 이벤트의 발생 횟수나 속도를 기반으로 하는 룰(예: "5분 이내 3회 이상 로그인 실패")에서 임계값을 너무 낮게 설정하거나 고정값으로 설정된 경우 정상적인 사용자 활동(예: 비밀번호를 잘못 입력하는 경우)도 위협으로 간주될 수 있습니다

3. (위협, 자산, 프레임워크 등) 컨텍스트 부족:

- 특정 이벤트가 발생했을 때, 해당 이벤트가 어떤 시스템에서, 어떤 사용자에게 의해, 어떤 시간대에, 어떤 공격으로 발생했는지 등의 컨텍스트 정보 없이 단편적인 이벤트만으로 판단하면 오탐이 발생하기 쉽습니다
 - 특정 IP에서 비정상적인 트래픽이 탐지되었지만, 알고 보니 해당 IP는 정상적인 시스템 업데이트 서버인 경우

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- 데이터 품질 문제
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. 정상 행위 정의 부족:

- SIEM은 네트워크, 시스템, 사용자 등의 '정상' 행동 패턴에 대한 기준선(Baseline)을 학습하고, 이 기준선에서 벗어나는 행위를 '비정상'으로 탐지하여 알람을 생성합니다
- 초기 설정 시 이 기준선이 정확하게 정의되지 않거나, 시간이 지남에 따라 환경 변화(새로운 시스템 도입, 사용자 변경, 비즈니스 변동 등)가 반영되지 않으면 오탐이 늘어납니다
 - 주말에 발생하는 백업 작업이나 보안 스캔은 평소와 다른 트래픽 패턴을 보이지만, 이를 정상 활동으로 기준선에 포함하지 않으면 오탐으로 보고될 수 있음

2. 비정상 행위가 정상 행위로 학습:

- 초기에 이미 비정상적인 활동이 발생하고 있었는데, 이를 정상으로 학습하여 기준선에 포함시키는 경우도 있습니다. 이 경우 해당 비정상 활동은 더 이상 탐지되지 않거나, 기준선 자체가 잘못되어 다른 정상 활동을 비정상으로 오인할 수 있습니다

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- **데이터 품질 문제**
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. 로그의 노이즈(Noise) 또는 불필요한 데이터:

- 관련성 없는 불필요한 정보(노이즈)가 과도하게 포함되어 있으면, 분석의 정확도가 떨어지고 오탐을 유발할 수 있습니다

2. 데이터 소스 오설정 또는 누락:

- 잘못된 필드 매핑: 로그가 CIM으로 매핑될 때 필드 매핑(예: 소스 IP, 목적지 IP, 사용자 이름 등)이 잘못되면, 룰이 올바르게 작동하지 않아 오탐을 유발합니다
- 잘못된 시간 동기화(Time Sync): 여러 데이터 소스의 시간 동기화가 맞지 않으면, 이벤트 발생 순서를 잘못 판단하여 상관관계 분석이 틀어지고 오탐이 발생할 수 있습니다
- 일부 중요 로그 누락: 특정 데이터 소스에서 중요한 로그가 누락되면, 전체적인 맥락 파악이 어려워지고, 불완전한 정보로 인해 오탐이 발생할 수 있습니다

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- 데이터 품질 문제
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. 오래되거나 부정확한 TI:

- SIEM은 외부 위협 인텔리전스(블랙리스트 IP, 악성 도메인, 파일 해시 파일 평판 등)를 활용하여 탐지 정확도를 높입니다. 하지만 이 위협 인텔리전스 데이터가 오래되었거나, 잘못된 정보(예: 과거에 악성으로 분류되었으나 현재는 정상적인 IP)를 포함하고 있으면 해당 정보를 기반으로 한 오탐이 발생합니다

2. 조직의 환경에 맞지 않는 TI:

- 모든 위협 인텔리전스가 모든 조직에 100% 유용한 것은 아닙니다. 조직의 비즈니스 특성이나 지역적 특성을 고려하지 않고 무분별하게 적용하면 오탐 가능성이 높아집니다

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- 데이터 품질 문제
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. 조직의 IT 환경 변화:

- 새로운 애플리케이션 도입, 클라우드 마이그레이션, 네트워크 구성 변경, 재택근무 도입 등 조직의 IT 환경이 변화해도 SIEM 룰이나 기준선이 업데이트되지 않으면, 정상적인 활동이 비정상으로 탐지될 수 있습니다
 - 새로운 개발팀이 특정 민감 서버에 접근하는 권한을 받았지만, SIEM 룰에는 이 예외가 반영되지 않아 계속해서 알람이 발생하는 경우

2. 정기적인 유지보수/스캔 활동:

- 정기적인 취약점 스캔, 침투 테스트, 패치 적용, 백업 작업 등은 네트워크에 비정상적인 트래픽이나 활동을 유발할 수 있지만, 이는 정상적인 운영 활동입니다. SIEM에서 이러한 활동을 예외 처리하지 않으면 오탐으로 이어집니다

FP (False Positive, 오탐) 발생 원인

오탐이 많아지면 알람 피로(Alert Fatigue)가 발생하여 정작 중요한 실제 위협을 놓치게 될 수 있으며, 불필요한 조사에 시간과 리소스를 낭비하게 됩니다.

- 과도하게 광범위하거나 민감한 탐지 룰
- 부정확하거나 오래된 기준선
- 데이터 품질 문제
- 위협 인텔리전스 (Threat Intelligence)의 품질 문제
- 비즈니스 프로세스 및 환경 변화 미반영
- 휴먼 에러 및 지식 부족

1. SIEM 운영자의 경험 부족:

- SIEM 시스템은 복잡하며, 효과적인 운영을 위해서는 심층적인 네트워크, 시스템, 보안 지식이 요구됩니다. 경험이 부족한 운영자는 룰을 잘못 구성하거나, 오탐 원인을 정확하게 분석하지 못할 수 있습니다

2. 탐지 룰의 복잡성:

- 너무 복잡하게 설계된 룰은 오히려 관리하기 어렵고, 특정 시나리오에서 예상치 못한 오탐을 유발할 수 있습니다.

3. 지속적인 튜닝의 부재:

- SIEM 시스템은 한번 구축하면 끝이 아니라, 지속적인 튜닝과 개선이 필요한 솔루션입니다. 이러한 튜닝 노력이 부족하면 시간이 지남에 따라 오탐율이 증가할 수 있습니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

1. 로그 누락 또는 불충분한 범위:

- 공격자가 사용하는 특정 시스템이나 애플리케이션의 로그가 아예 Splunk로 수집되지 않는 경우입니다. 로그가 없으므로 해당 시스템에서 발생하는 위협은 근본적으로 탐지가 불가능합니다
 - 공격자가 회사 내부에 침투한 후, Linux 서버에서 root 권한을 탈취하여 데이터베이스에 접근했습니다. 하지만 해당 Linux 서버의 syslog나 auditd 로그가 Splunk로 수집되지 않고 있었습니다. 이 경우, 권한 탈취나 데이터베이스 접근 시도와 같은 모든 공격 행위는 Splunk 기록되지 않아 미탐으로 이어집니다

2. 부정확한 필드 추출:

- 정규식을 사용하여 로그에서 IP 주소, 사용자 이름, 파일 해시 등과 같은 중요한 필드를 추출합니다. 이 필드 추출 방법(정규식)이 잘못되면, 탐지 룰이 필요한 정보를 찾지 못해 미탐지가 발생합니다
 - 최신 웹 브라우저의 제로데이 취약점을 이용한 Drive-by-download 공격이 발생했습니다. 공격자는 사용자가 특정 웹사이트에 접속만 해도 악성코드가 다운로드되도록 했습니다. 이 공격은 기존의 시그니처나 패턴과 다르기 때문에, 기존 웹 프록시 탐지 룰로는 이 악성 다운로드를 탐지하지 못하고 미탐으로 이어집니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

3. 잘못된 필드 정규화:

- Common Information Model(CIM)을 통해 다양한 소스의 로그를 표준화된 필드명으로 변환(정규화)합니다. 이 과정에서 필드 매핑이 잘못되면, 탐지 룰이 필요한 필드를 찾지 못해 작동하지 않습니다
 - 방화벽 로그의 state 필드가 CIM의 action 필드로 올바르게 매핑되어야 합니다. 그런데 Splunk 관리자가 매핑 설정을 잘못하여 방화벽의 action=drop 이벤트가 action 필드가 아닌 다른 필드로 저장됩니다. "Blocked Connections" 룰은 CIM의 action=block 또는 action=drop을 기반으로 탐지하므로, 잘못 매핑된 로그는 룰 적용 대상에서 제외되어 미탐이 됩니다
 - "권한 상승" 탐지 룰이 Authentication 데이터 모델에서 status=success인 로그인 이벤트와 Privilege Escalation 이벤트를 상호 연관시킵니다. 하지만 로그인 성공 로그가 제대로 정규화되지 않아 Authentication 데이터 모델에 포함되지 못하므로, 이후의 권한 상승 시도를 탐지하지 못하게 됩니다.

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

1. 알려지지 않은 위협(Zero-Day Exploits)에 대한 룰 부재:

- SIEM의 많은 탐지 룰은 이미 알려진 공격 패턴(시그니처)을 기반으로 합니다. 아직 외부에 공개되지 않은 제로데이 취약점을 이용한 공격은 이러한 시그니처 기반 룰으로는 탐지하기 어렵습니다
 - 최신 웹 브라우저의 제로데이 취약점을 이용한 Drive-by-download 공격이 발생했습니다. 공격자는 사용자가 특정 웹사이트에 접속만 해도 악성코드가 다운로드되도록 했습니다. 이 공격은 기존의 시그니처나 패턴과 다르기 때문에, Splunk의 기존 웹 프록시 탐지 룰으로는 이 악성 다운로드를 탐지하지 못하고 미탐지로 이어집니다

2. 공격자 우회 기술에 대한 대응 부족:

- 공격자들은 SIEM 탐지 시스템을 우회하기 위해 다양한 기술을 사용합니다. 탐지 룰이 이러한 우회 기술을 고려하지 않으면 미탐지가 발생합니다
 - "1분 내 100회 이상 로그인 실패 시 알림"이라는 룰이 있습니다. 공격자는 이 룰을 피하기 위해 로그인 시도 횟수를 1분당 99회로 조절하거나, 1분마다 sleep 함수를 사용했습니다. Splunk 룰은 이러한 변형된 공격을 탐지하지 못하고 미탐지됩니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

3. 단편적인 이벤트에 기반한 룰:

- 여러 개의 분리된 이벤트가 특정 시간 간격을 두고 발생할 때, 이를 연결하여 하나의 위협 시나리오로 판단하는 상관관계 분석 룰이 부족하면 미탐지가 발생합니다
 - 공격자가 먼저 내부 시스템의 포트 스캔을 수행하고(이벤트 1), 3시간 후에 발견된 취약점을 이용해 SQL Injection 공격을 시도했습니다(이벤트 2). 만약 Splunk에 이벤트 1과 이벤트 2를 연결하여 "공격자가 스캔 후 취약점 공격 시도"라는 시나리오를 탐지하는 상관관계 룰이 없다면, 두 이벤트는 각각 낮은 심각도의 개별 이벤트로 처리되어 전체적인 위협은 미탐지될 수 있습니다.

4. 정적(Static) 임계값:

- 특정 수치를 기준으로만 위협을 탐지하도록 룰을 설정하면, 그 임계값보다 약간 낮은 수준의 공격은 모두 미탐 처리됩니다. 예를 들어, 한 IP에서 1분 동안 100회 이상의 로그인 실패를 탐지하도록 룰을 설정했다면, 공격자가 99회만 시도할 경우 탐지되지 않습니다
 - A라는 악성 IP가 봇넷을 이용해 웹 서버에 분산된 로그인을 시도합니다. "Brute Force" 룰은 1분 내 50회 이상의 로그인 실패를 탐지하지만, 공격자는 59초 동안 49회만 시도하고 잠시 멈췄다가 다시 시작하는 방식으로 탐지 룰을 회피합니다. 이 경우, 모든 시도들이 탐지 임계값 미만으로 발생하여 미탐이 됩니다.

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

5. 공격 기법의 진화에 대한 대응 미흡:

- 공격자들은 항상 새로운 공격 기법을 개발하여 기존의 보안 시스템을 우회하려 합니다. 탐지 룰이 이러한 최신 공격 트렌드를 반영하지 못하면 미탐은 필연적으로 발생합니다
 - LOLBins (Living Off the Land Binaries) 공격: SIEM 룰이 mimikatz.exe와 같은 알려진 해킹 도구의 실행을 탐지하도록 정의되어 있습니다. 공격자가 powershell.exe, psexec.exe 등 윈도우에 기본으로 설치된 합법적인 도구를 사용하여 공격합니다. 이 도구들의 실행은 일반적인 시스템 관리 행위로 간주되므로, 기존의 룰은 이를 위협으로 인식하지 못합니다
 - 터널링 및 데이터 유출: SIEM 룰이 대용량의 파일 전송(bytes_sent > 1GB)을 데이터 유출로 탐지하도록 설정되어 있습니다. 공격자가 DNS 터널링과 같이 소량의 데이터를 여러 번에 걸쳐 전송하는 방식으로 데이터를 유출합니다. 각 전송량은 룰의 임계값보다 작기 때문에, SIEM은 이를 정상적인 DNS 질의 응답으로 판단하고 미탐이 발생합니다.

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

1. 위협 인텔리전스(Threat Intelligence) 부족:

- 새로운 C2(Command & Control) 서버 통신 미탐: ML 모델은 정상적인 네트워크 트래픽의 기존 패턴을 학습하여 비정상적인 트래픽 급증이나 포트 사용 등을 탐지할 수 있습니다. 하지만 해당 도메인 자체가 악성이라는 컨텍스트 정보가 없기 때문에, 통신량이나 포트 사용이 정상 범주 내라면 이를 위협으로 인식하지 못합니다
 - 공격자가 내부 시스템에 악성코드를 설치하고, 평소와 비슷한 통신량으로 새로운 C2 서버에 접속합니다. 이 도메인이 Splunk에 연동된 TI 데이터베이스에 포함되어 있지 않다면, ML 모델은 이를 단순한 외부 통신으로 간주하여 미탐이 발생합니다
- 악성 파일 다운로드 미탐: 공격자가 합법적인 클라우드 스토리지 서비스(예: Dropbox, OneDrive)를 통해 악성 파일을 다운로드하도록 유도합니다. ML 모델은 트래픽의 크기, 프로토콜, 출발지/목적지 정보 등을 분석할 수 있지만, 다운로드된 파일의 해시값이 악성인지에 대한 컨텍스트 정보가 없습니다.
 - 사용자가 Dropbox에서 해킹 도구를 다운로드했습니다. ML 모델은 평소와 다른 파일을 다운로드했다는 점을 감지할 수 있지만, 해당 파일의 해시값이 악성 해시 데이터베이스에 없거나 Splunk에 연동되지 않았다면 이를 위협으로 분류하지 못합니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

1. 머신러닝 기반 이상탐지의 한계:

- 알려지지 않은 공격 기법 (Zero-day Attack): 모델이 학습한 데이터셋에는 이미 알려진 공격 패턴(예: 특정 악성코드의 네트워크 통신, 비정상적인 로그인 시도)만 포함되어 있습니다
 - 공격자가 완전히 새로운 랜섬웨어 변종을 사용하여 침투했을 때, 이 변종의 행위는 학습 데이터에 없으므로 모델은 이를 정상적인 활동으로 오인하고 탐지하지 못합니다.
- 정상 행위 패턴의 불충분한 학습: 모델이 학습한 정상 데이터가 특정 시간대(예: 업무 시간)나 특정 그룹(예: 일반 사용자)의 데이터에만 편중되어 있습니다
 - 심야 시간에 시스템 관리자가 평소와 다른 방식으로 서버에 접근했을 때, 모델은 이 행위를 "비정상"으로 분류할 수 있습니다. 반대로, 공격자가 시스템 관리자의 계정을 탈취하여 주말에 비정상적인 작업을 수행했음에도 불구하고, 모델은 정상적인 관리 행위와 구별하지 못해 미탐이 발생할 수 있습니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

2. 부적절한 학습 데이터:

- 비정상 행위 탐지(UBA) 모델은 정상적인 사용자 행위를 학습하여 기준점을 만듭니다. 학습 데이터에 비정상적인 행위가 포함되어 있으면, 모델이 이를 정상으로 오인하여 이후 유사한 비정상 행위를 탐지하지 못하게 됩니다
 - A 사용자가 주말에도 회사 서버에 접속하여 대용량 파일을 다운로드하는 것이 일상적인 업무입니다. 보안 분석가는 이 패턴을 정상적인 것으로 간주하고 모델 학습 데이터에 포함시킵니다. 이후 공격자가 A 사용자의 계정을 탈취하여 주말에 대량의 데이터를 유출할 때, ML 모델은 이 행위를 A 사용자의 "정상적인" 패턴으로 인식하고 알림을 생성하지 않아 미탐이 됩니다

3. 모델의 부적절한 선택 및 매개변수 설정 오류:

- 임계값(Threshold)의 오류: 이상 징후를 점수화하는 모델(예: DensityFunction, Isolation Forest)의 탐지 임계값을 너무 높게 설정했습니다
 - 모델이 특정 행위에 대해 '위험도 점수 0.7'을 부여했지만, 관리자가 설정한 임계값이 0.8이어서 해당 위협을 경고로 트리거하지 못하고 놓치는 경우입니다. 보안팀은 미묘한 위협 신호를 놓치게 됩니다.
- 잘못된 알고리즘 선택: 시계열 데이터의 비정상적인 트래픽 급증을 탐지해야 하는데, 비시계열 데이터에 적합한 군집 분석(Clustering) 모델을 사용했습니다

FN (False Negative, 미탐) 발생 원인

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

- 로그 수집 및 데이터 처리 문제
- 탐지 룰의 한계와 미흡한 정의
- 위협 인텔리전스 및 컨텍스트 정보 부족
- ML 모델 및 분석가의 미탐 튜닝 문제

4. 데이터 패턴의 변화:

- 데이터 패턴의 변화: 새로운 애플리케이션이나 서비스가 도입되어 네트워크 트래픽 패턴이 급격히 변동했습니다
 - 모델이 정상 트래픽으로 학습한 데이터는 주로 HTTP/S 포트를 사용하는 트래픽이었는데, 새로운 서비스가 UDP 기반의 트래픽을 대량으로 생성하기 시작했습니다. 모델은 이 새로운 패턴을 "비정상"으로 오인하거나, 반대로 악의적인 UDP 트래픽을 "정상"으로 간주하여 미탐이 발생할 수 있습니다
- 데이터 드리프트 (Data Drift): 시간이 지남에 따라 정상적인 사용자 행위의 기준이 점진적으로 변하는 현상. 예를 들어, 사용자들이 재택근무로 전환하면서 로그인 시간과 IP 주소 패턴이 크게 바뀌었습니다
 - 공격자가 재택근무 시간대에 사용자 계정을 탈취하여 원격 접속을 시도했지만, 모델이 이미 변화된 정상 패턴에 익숙해져 이를 비정상으로 탐지하지 못하는 경우입니다

FP (False Positive, 오탐) & FN (False Negative, 미탐) 방지 방안

미탐이 많아지면 실제 위협이 발생했음에도 불구하고 시스템이 이를 탐지하지 못하고 알림을 생성하지 않는 경우를 말합니다. 이는 오탐(False Positive)보다 훨씬 더 심각한 문제로, 실제 보안 침해로 이어질 수 있는 치명적인 결과를 초래할 수 있습니다.

FP (False Positive, 오탐) 방지 방안

- 탐지 룰(Rule)의 정교화:** 룰을 처음 만들 때 지나치게 포괄적으로 정의하면 오탐이 많아짐
 - 동적 임계값으로 설정
 - 예외 처리
 - 다단계 상관관계 분석
- 컨텍스트 정보 강화:** 로그 자체에 없는 정보를 추가하여 경보의 정확도를 높임
 - 자산 중요도에 따른 활용
 - 위협 인텔리전스 활용
- 자동화된 분석 및 대응(SOAR):** SOAR 플랫폼을 활용하여 오탐 가능성이 높은 경보를 자동으로 분류하고 조사하여 분석가들의 수동 작업을 줄임
- 지속적인 튜닝:** 정기적으로 오탐 사례를 검토하고, 이에 따라 룰을 수정하는 피드백 루프를 구축
- 머신러닝 및 이상탐지 도입:** 기존 룰 기반 탐지의 한계를 넘어서기 위해, ML 알고리즘과 이상행위 탐지
 - 정상/비정상 패턴을 지속적으로 학습하며, '알려지지 않은' 공격 탐지
 - 정확도 개선을 위한 재학습, 피드백 루프 도입

FN (False Negative, 미탐) 방지 방안

- 로그 가시성 확장:** SIEM에 모든 중요한 로그 소스가 연결되어 있는지 확인
 - 로그 수집 범위 확장
 - 필드 누락 방지
- 행위 기반 탐지(Behavioral-based Detection) 도입:** 시그니처 기반 룰의 한계를 보완하기 위해 머신러닝(ML)을 활용한 행위 기반 탐지를 도입
 - ML 모델 학습
 - ML 모델 재학습
- 위협 헌팅(Threat Hunting):** 자동화된 탐지 시스템이 놓칠 수 있는 위협을 찾기 위해 보안 분석가가 주도적으로 위협 헌팅을 수행
 - 가설 기반 헌팅: 공격자가 내부망에서 수평 이동(Lateral Movement)을 시도할 것이다와 같은 가설을 세우고, 관련 로그를 직접 검색하고 분석하여 잠재적 위협을 식별
- 최신 위협 인텔리전스 통합:** 새로운 공격 기법이나 악성 도메인에 대한 정보를 빠르게 SIEM에 반영하여 기존 룰을 보완
- TI 피드 연동:** 위협 인텔리전스 피드를 SIEM에 연동하여 최신 IoC, IoA를 자동으로 탐지 룰에 적용

Splunk AI

임베디드 AI 및 머신러닝을 통한 디지털 복원력 촉진



AI for Security - Enterprise Security, UBA -

머신러닝 기반 탐지, 비정상적인 사용자 행위



AI for Observability - ITSI, APM, IM, On-Call -

예측 분석, 이상 탐지, 적응형 임계값,
사고 상관 관계, 경고 소음 감소, 경고 자동 감지

Assistive Intelligence Experiences

Splunk AI Assistant, Splunk App for Anomaly Detection



Customizable ML

Splunk Machine Learning Toolkit, Splunk App for Data
Science and Deep Learning, Python for Scientific
Computing


The Splunk Platform

통계 분석, 예측 분석 및 클러스터링을 위한 강력한 검색 명령

New AI Assistant for SPL

GPU 기반 클라우드 AI 서비스로 구동

- ▶ 관리자 및 운영자의 Splunk 관리 기술 향상
- ▶ AI Assistant를 통한 SPL 작성 및 설명 확인



New AI Assistant for Security

- ▶ AI Assistant를 이용한 신속한 조사
- ▶ 분석가 질문에 답변을 제공함으로써 분석 워크플로우 속도 높임
- ▶ 시간 절약과 동시에 보다 신속하게 위협 대처 가능

The screenshot displays the Splunk Security Console interface. The main panel shows an investigation titled "Geographically Improbable Access Detected 392.398.23". The investigation details include:

- Overview:** Includes findings such as "Excessive failed logins", "Threat Activity Detected from 10.163.194.46 to 8...", "Possible phishing attack user tim_tailor837726", and "AWS Cloud Provisioning From Previously Unseen I...".
- Custom fields:** Related Jira ticket (RDMP-334), Related SNOW ticket, ID (ES-87416), Correlation search (Geographically Improbable Acc), Severity (High), Included findings (4), and Description (This investigation is created when the location of the log...).
- Basic info:** ID (ES-87416), Correlation search (Geographically Improbable Acc), Severity (High), Included findings (4), and Description (This investigation is created when the location of the log...).
- Events:** event_hash (da9f475219f5fc96df67...), eventtype (modnotable_results), and notable.
- Location:** src (10.206.12.17), src country (China), src city (Beijing), dst (231.23.123.23), dst country (USA), dst city (San Jose), and dst expected (True).
- Users:** name (Tim Tailor), username (Ttailor07), user id (290838299), email address (ttailor@ac...), department (Sales), hire date (10/09/2...), device name (Tim Mac...), device id (982374...), and device location (23.32.68...).

The right sidebar shows the "AI Assistant" chat interface. The chat history includes:

- Sara Jones:** 2:04 PM. Which host downloaded the files?
- AI assistant:** 2:04 PM. Sure, I can help with that. The following query can download the files?"
- SPL:** | tstats count WHERE index=index_01 sourcet... action="download" by host
- Sara Jones:** 2:04 PM. Run query

스플링크 플랫폼에서의 커스텀 ML

앱 에코시스템

Splunk의 App Ecosystem에는 데이터를 가져오고, 구조를 적용하며, 데이터를 시각화하여, 가치 창출 시간을 단축 할 수있는 1000 가지의 무료 애드온이 포함되어 있습니다.





MLTK

Machine Learning Toolkit은 다양한 ML 개념을 탐색하기위한 새로운 SPL 명령, 커스텀 시각화, 어시스턴스 및 예제를 제공합니다.

Splunk

Splunk Enterprise는 머신 데이터의 인덱스 생성, 검색, 분석, 경고 및 시각화를 위한 미션 크리티컬 플랫폼입니다.

데이터 사이언스 파이프라인

Collect
DataClean &
MungeSearch &
ExplorePre-processing
Feature SelectionChoose
AlgorithmBuild, Test,
Improve ModelsOperationalize
Monitor AlertVisualize &
Share

앱 에코시스템

Splunk

앱 에코시스템

Splunk

Splunk

MLTK

Splunk

MLTK

Splunk

MLTK

Splunk

MLTK


Splunk

앱 에코시스템


Splunk

splunk > 운영 인텔리전스를 위한 플랫폼

머신러닝 워크플로우 (Splunk)




Splunk는 무엇을 할 수 있나요?



아웃라이어 탐지

- 비지도 학습

여기!



Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

The screenshot displays the Splunk Machine Learning Toolkit interface. At the top, the 'Experiments' tab is selected in the navigation bar. Below the navigation bar, a row of experiment cards is shown. The 'Smart Outlier Detection' card is highlighted with a pink box and a pink circle with the number 1. To the right of this row, a green 'Create New Experiment' button is highlighted with a pink box and a pink circle with the number 2. A red arrow points from this button to the 'Create New Experiment' dialog box below. The dialog box has a title bar 'Create New Experiment' with a close button. It contains three fields: 'Experiment Type' with a dropdown menu set to 'Smart Outlier Detection', 'Experiment Title' with the text 'mytrack_density' (highlighted with a pink box), and 'Description' with the text 'Optional'. At the bottom right of the dialog, there are two buttons: 'Cancel' and 'Create' (highlighted with a pink box and a pink circle with the number 3).

Experiments

Smart Forecasting 1

Smart Outlier Detection 3

Smart Clustering 2

Smart Prediction 4

Predict Numeric Fields 0

Predict Categorical Fields 5

Detect Numeric Outliers 3

Detect Categorical Outliers 0

Forecast Time Series 1

Cluster Numeric Events 0

Create New Experiment

Create New Experiment

Experiment Type Smart Outlier Detection ▼

Experiment Title mytrack_density

Description Optional

Cancel Create

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

1. 데이터 입력하기

| inputlookup mytrackdata.csv

Smart Outlier Detection: mytrack_density

Define Data Source View history

Q 검색 □ 데이터 집합 ◇ Metrics

| inputlookup mytrackdata.csv

✓ 6,000개의 결과 (70/01/01 9:00:00.000 ~ 24/06/29 16:02:26.000) 작업 || 스마트 모드

데이터 미리보기 시각화

20 Per Page < 이전 1 2 3 4 5 6 7 8 9 10 다음 >

x_batteryVoltage	x_engineCoolantTemperature	x_engineSpeed	x_lateralGForce	x_longitudeGForce	x_speed
13.828	79.0	4326	0.13	-0.86	54
13.855	86.0	4913	0.15	-1.01	60
13.827	93.0	6542	0.49	-0.18	

2. 데이터 분포를 활용한 아웃라이어 탐지

Learn Data

> Initial data - search

▼ Detect Outliers

Field to analyze ?
x_batteryVoltage

Split by fields
y_vehicleType (1)

Distribution type ?
Auto

Outlier tolerance threshold
0.0001 0.003

Notes
(optional)


Detect Outliers

- threshold 파라미터는 백분율을 나타내며 0.000000001(0%를 나타냄)과 1(100%를 나타냄) 사이의 값을 가짐
- DensityFunction 알고리즘이 적합 분포에서 아웃라이어 영역을 표시하도록 안내, 예를 들어, threshold=0.01인 경우 적합 밀도 함수의 1%가 아웃라이어 영역으로 설정

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

3. 차종(vehicleType) 별 아웃라이어 확인



Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

4. Experiment 저장

Smart Outlier Detection: mytrack_density

Draft

취소

저장

< 뒤로

Save and Next >

Detect outliers in **x_batteryVoltage**, split by **y_vehicleType**, using **Auto** distribution with a threshold of **0.003**

Define

Learn

검토

Operationalize

Review Experiment

Model Summary ?

Cardinality Histogram ?

Distribution Properties ?

Outlier Analysis ?

20 Per Page ▾

y_vehicleType ▾	type ▾	min ▾	max ▾	mean ▾	std ▾	ca
2008 BMW M3	Auto: Gaussian KDE	13.472	14.019	13.852	0.03594548650387136	
2011 Ferrari 458	Auto: Gaussian KDE	13.467	14.095	13.929469000000001	0.132537160973819	
2011 Ford Mustang GT500	Auto: Gaussian KDE	13.169	14.235	13.846172000000001	0.16095567220822007	
2013 Audi RS5	Auto: Gaussian KDE	12.783	14.485	14.076845	0.2112032219806317	
2014 Chevrolet Corvette	Auto: Gaussian KDE	14.351	15.409	14.714542000000002	0.1620908764736622	
2015 Porsche GT3	Auto: Gaussian KDE	13.716	14.319	14.047572	0.13215600938285024	

Save Experiment

⚠ Saving your experiment will update any scheduled training and alerts associated with this experiment.

Experiment Title

mytrack_density

설명

mytrack_density

취소

저장

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

5. 모델 저장, 모델을 이용한 경고 만들기, 주기적인 모델 학습 설정

Showcase
Experiments
검색
Models
설정
Docs
Video Tutorials
 Splunk Machine Learning Toolkit

Smart Outlier Detection: mytrack_density
< 뒤로
완료

Detect outliers in **x_batteryVoltage**, split by **y_vehicleType**, using **Auto** distribution with a threshold of **0.003**

Define
Learn
검토
Operationalize

Operationalize Outlier Detection

Publish Outlier Models

경고 만들기

경고 관리

Schedule Model Training

View Scheduled Training Jobs

Publish the Models

Publishing an Experiment model means the main model with any associated preprocessing models will be copied as lookup files in the user's namespace within the selected destination app.

New Main Model Title
mytrack_density

Model names must start with a letter or underscore and contain only letters, numbers, and underscores

대상 앱
Splunk Machine Learning Toolkit

취소
제출

Models have been published

You can find the models under [Settings > Lookups > Lookup Table Files](#). You may now use the published models to create alerts or schedule model training.

To create an alert, you can use the below SPL snippet in your search:

... | apply mytrack_density

SPL 사용 방법에 대한 가이드

확인

모델 저장

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

5. 모델 저장, 모델을 이용한 경고 만들기, 주기적인 모델 학습 설정

Showcase Experiments **검색** Models 설정 Docs Video Tutorials

Splunk Machine Learning Toolkit

Smart Outlier Detection: mytrack_density

Detect outliers in **x_batteryVoltage**, split by **y_vehicleType**, using **Auto** distribution with a threshold of **0.003**

- Define
- Learn
- 검토
- Operationalize

Operationalize Outlier Detection

Publish Outlier Models

경고 만들기

경고 관리

Schedule Model Training

View Scheduled Training Jobs

경고로 저장

설명		
감역	<code> inputlookup mytrackdata.csv apply "_exp_b476d0f8c2c4b7e8aa07e7ee0c0e77"</code>	
Title	mytrack_density_경고1	
설명	선택 사항	
권한	비공개	앱에서 공유됨
경고 유형	예약됨	실시간
메시지	매일 실행 ▼	
만료	365	일 ▼
트리거 조건	Machine Learning Conditions ▼	
경고 트리거 시기	Number of outliers ▼	
트리거	한 번	각 결과에 대해
정보 조정 ?	☐	
트리거 작업	+ 작업 추가 +	

보고서 예약

스케줄	매일 실행 ▼	
메시지	1:00 ▼	
시간 범위	Last 30 days ▶	
예약 우선순위 ?	최고 ▼	
예약 참 ?	자동 ▼	
트리거 작업	+ 작업 추가 +	
트리거되는 경우	☒ 이메일 보내기	

받는 사람

원본으로 구성된 이메일 주소 리스트
CC 및 BCC 표시

우선순위: 정상 ▼

제목: Splunk Alert: \$name\$
이메일 제목, 수신인 및 메시지는는 검색 결과에 따라 텍스트를 삽입하는 후크가 포함될 수 있습니다. 자세히 알아보기

메시지: The scheduled report '\$name\$' has run.

포함 ☒ 보고서 링크 ☒ 결과 링크
☐ 전체 요약명 ☐ 원래의 데이터

경고 생성

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

5. 모델 저장, 모델을 이용한 경고 만들기, 주기적인 모델 학습 설정

Smart Outlier Detection: mytrack_density

Detect outliers in **x_batteryVoltage**, split by **y_vehicleType**, using **Auto** distribution with a threshold of **0.003**

Operationalize Outlier Detection

- Define
- Learn
- 검토
- Operationalize

Publish Outlier Models

경고 만들기

경고 관리

Schedule Model Training

View Scheduled Training Jobs

생성된 경고
확인

Alerts for Experiment: mytrack_density

경고는 트리거 검색의 결과가 포함된 이메일을 여러 사람에게 보내는 등 작업을 트리거하는 조건을 설정합니다. 경고를 볼 이름을 클릭하십시오. 매개 변수를 상세히 지정하려면 검색에서 경고를 여십시오.

1 경고

i	제목	경고 유형	트리거 조건	트리거 작업	상태	작업
>	mytrack_density_경고1	예약됨. 매일(2:00).	사용자 지정. * where 'IsOutlier(x_batteryVoltage)' = "1.0" stats count where 'count' > 0.	1개의 작업 Log Event	사용 가능	편집

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

5. 모델 저장, 모델을 이용한 경고 만들기, 주기적인 모델 학습 설정

Showcase Experiments 검색 Models 설정 Docs Video Tutorials

Splunk Machine Learning Toolkit

Smart Outlier Detection: mytrack_density

Detect outliers in **x_batteryVoltage**, split by **y_vehicleType**, using **Auto** distribution with a threshold of **0.003**

- Define
- Learn
- 검토
- Operationalize

Operationalize Outlier Detection

Publish Outlier Models

경고 만들기

경고 관리

Schedule Model Training

View Scheduled Training Jobs

보고서 예약

스케줄	매일 실행 ▶
해시판	100 ▼
시간 범위	Last 30 days ▶
예약 우선순위 ?	최고 ▼
예약 창 ?	자동 ▼
트리거 학습	+ 작업 추가 ▼
트리거되는 경우	이벤트 보내기 ▼
받는 사람	
우선순위	정상 ▼
제목	Splunk Alert: \$name\$ 이메일 제목, 수신인 및 메시지는 값에 따라 달라질 수 있습니다. 자세한 내용은 도움말을 참조하십시오.
메시지	The scheduled report '\$name\$' has run.
모형	☒ 보고서 링크 ☒ 결과 링크 ☐ 전체 유지됨 ☐ 90일이 지난 후 삭제

주기적인 모델 학습

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

6. 프러덕션 데이터에 모델 사용하여 아웃라이어 탐지

새로운 검색 다른 이름으로 저장 ▼ 테이블 보기 만들기 닫기

```

1 | inputlookup track_day.csv
2 | sample 5000 by vehicleType seed=1
3 | rename * as x_* , x_vehicleType as y_vehicleType
4 | apply mytrack_density
5 | search "IsOutlier(x_batteryVoltage)" = 1.0
6 | stats count by y_vehicleType
7 | sort - count
  
```

✓ 6개의 결과 (24/06/28 16:00:00.000 ~ 24/06/29 16:32:53.000) 이벤트 샘플링 없음 ▼ 작업 ▼ || ■ → ⌵ ⬇ ! 스마트 모드 ▼

이벤트 패턴 통계 (6) 시각화

페이지당 100개 ▼ 형식 미리보기 ▼

y_vehicleType ◆	count ◆
2008 BMW M3	42
2014 Chevrolet Corvette	9
2015 Porsche GT3	6
2011 Ford Mustang GT500	4
2011 Ferrari 458	1
2013 Audi RS5	1

```

| inputlookup track_day.csv
| sample 5000 by vehicleType seed=1
| rename * as x_* , x_vehicleType as y_vehicleType
| apply mytrack_density
| search "IsOutlier(x_batteryVoltage)" = 1.0
| stats count by y_vehicleType
| sort - count
  
```

IsOutlier 필드가 생성됨

(0 = normal , 1= outlier)

이제 경고를 사용할 수 있음

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미

6. 프러덕션 데이터에 모델 사용하여 아웃라이어 탐지

새로운 검색 다른 이름으로 저장 ▼ 테이블 보기 만들기 닫기

```

1 | inputlookup track_day.csv
2 | sample 5000 by vehicleType seed=1
3 | rename * as x_* , x_vehicleType as y_vehicleType
4 | apply mytrack_density
5 | search "IsOutlier(x_batteryVoltage)" = 1.0
6 | stats count by y_vehicleType, "IsOutlier(x_batteryVoltage)"
7 | sort - count

```

✓ 12개의 결과 (24/06/28 16:00:00.000 ~ 24/06/29 16:37:19.000) 이벤트 샘플링 없음 ▼ 작업 ▼ || ■ → 🖨 ⬇ ! 스마트 모드 ▼

이벤트 패턴 통계 (12) 시각화

페이지당 100개 ▼ 🔍 형식 미리보기 ▼

y_vehicleType	IsOutlier(x_batteryVoltage)	count
2011 Ferrari 458	0.0	4999
2013 Audi RS5	0.0	4999
2011 Ford Mustang GT500	0.0	4996
2015 Porsche GT3	0.0	4994
2014 Chevrolet Corvette	0.0	4991
2008 BMW M3	0.0	4958
2008 BMW M3	1.0	42
2014 Chevrolet Corvette	1.0	9
2015 Porsche GT3	1.0	6
2011 Ford Mustang GT500	1.0	4
2011 Ferrari 458	1.0	1
2013 Audi RS5	1.0	1

```

| inputlookup track_day.csv
| sample 5000 by vehicleType seed=1
| rename * as x_* , x_vehicleType as y_vehicleType
| apply mytrack_density
| stats count by y_vehicleType,
  "IsOutlier(x_batteryVoltage)"
| sort - count

```

IsOutlier 필드가 생성됨
(0 = normal , 1= outlier)

Outlier (아웃라이어) 탐지

데이터 집합 내에서 '정상'과 현저하게 다른 이상값(이상치, outlier 또는 anomaly)을 자동으로 찾아내는 기법을 의미


7. 생성된 모델 정보 확인

새로운 검색									
1 summary mytrack_density									최근 24시간
6개의 결과 (24/06/28 16:00:00.000 ~ 24/06/29 16:43:30.000) 이벤트 샘플링 없음									
이벤트 (0) 패턴 통계 (6) 시각화									
페이지당 100개 형식 미리보기									
y_vehicleType	type	min	max	mean	std	cardinality	distance	other	
2008 BMW M3	Auto: Gaussian KDE	13.472	14.019	13.852	0.03594548650387136	1000	metric: wasserstein, distance: 0.0023107323042705994	bandwidth: 0.00902909798230852, parameter size: 1000	
2011 Ferrari 458	Auto: Gaussian KDE	13.467	14.095	13.929469000000001	0.132537160973819	1000	metric: wasserstein, distance: 0.0071173706669067	bandwidth: 0.033291829632093706, parameter size: 1000	
2011 Ford Mustang GT500	Auto: Gaussian KDE	13.169	14.235	13.846172000000001	0.16095567220822007	1000	metric: wasserstein, distance: 0.009048545955320068	bandwidth: 0.04043023690943316, parameter size: 1000	
2013 Audi RS5	Auto: Gaussian KDE	12.783	14.485	14.076845	0.2112032219806317	1000	metric: wasserstein, distance: 0.012236501818789958	bandwidth: 0.05305185075842547, parameter size: 1000	
2014 Chevrolet Corvette	Auto: Gaussian KDE	14.351	15.409	14.714542000000002	0.1620908764736622	1000	metric: wasserstein, distance: 0.00905890668269594	bandwidth: 0.04071538732856875, parameter size: 1000	
2015 Porsche GT3	Auto: Gaussian KDE	13.716	14.319	14.047572	0.13215600938285024	1000	metric: wasserstein, distance: 0.009093614298959959	bandwidth: 0.03319608868112343, parameter size: 1000	

| [summary](#) mytrack_density

Regrssion (회귀) 모델 만들기 - 지도학습

여기!



Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

Experiments

0 Experiments

Filter by experiment name

i	Experiment Name	Algorithm			Actions
---	-----------------	-----------	--	--	---------

Create New Experiment

Experiment Type

Predict Numeric Fields ▼

Experiment Title

mytrack_regression

설명

Optional

취소

Create

Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

1. 데이터 입력하기

Predict Numeric Fields: mytrack_regression

Predict the value of a numeric field using a weighted combination of the values of other fields in that event.

Experiment Settings Experiment History

Enter a search

| inputlookup mytrackdata.csv

Preprocessing Steps

No steps added.

알고리즘에 대해서:

ElasticNet :

<https://docs.splunk.com/Documentation/MLApp/latest/User/Algorithms#ElasticNet>

2. 알고리즘, 종속(목적) 변수 설정, 독립(입력) 변수 설정, 학습/테스트 비율 설정

Algorithm Field to predict Fields to use for predicting Split for training / test: 70 / 30

LinearRegression x_engineCoolantTempe... x_batteryVoltage, x_... (7)

Fit Intercept

☒ estimate the intercept

Notes

(optional)

Fit Model 검색에서 열기 Show SPL

Fit a model on all your data in search [↗](#)

```
| inputlookup mytrackdata.csv
| fit LinearRegression "x_engineCoolantTemperature" from "x_batteryVoltage"
"x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed"
"x_verticalGForce" "y_vehicleType" fit_intercept=true into
"_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
```

Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

3. 실제값, 예측값 및 잔차

Prediction Results [↗](#)

x_engineCoolantTemperature ↕	predicted(x_engineCoolantTemperature) ↕	residual ↕	x_batteryVoltage ↕	x_engineSpeed ↕	x_lateralGForce ↕	x_longitudeGForce ↕	x_speed ↕	x_verticalGForce ↕	y_vehicleType ↕
86.0	83.54	2.5	13.855	4913	0.15	-1.01	60	-0.63	2008 BMW M3
105.0	106.80	-1.8	14.562000000000001	3907	0.48	0.65	90	-0.17	2014 Chevrolet Corvette
90.0	94.59	-4.6	13.710999999999999	3755	1.08	-0.81	80	-2.0	2011 Ford Mustang GT500
90.0	94.29	-4.3	13.812000000000001	5823	-0.98	-0.59	86	-2.0	2015 Porsche GT3
	64.31		13.815	4500	-0.04	-0.02	70	1.13	2013 Audi RS5
89.0	94.50	-5.5	13.815	5776	-0.12	0.53	102	-2.0	2015 Porsche GT3
88.0	92.81	-4.8	13.664000000000001	1159	1.01	0.02	23	-2.0	2011 Ford Mustang GT500
84.0	83.64	0.4	13.999	1764	0.94	-0.03	40	-0.15	2011 Ferrari 458
84.0	85.10	-1.1	13.880999999999998	6254	-0.03	-0.92	78	0.01	2008 BMW M3
2.0	61.35	-59.3	13.931	5664	0.71	-0.67	72	0.62	2013 Audi RS5

« 이전 1 2 3 4 5 6 7 8 9 10 다음 »

검색에서 열기 [↗](#)

Show SPL

Display the actual and predicted values of the "field to predict" [↗](#)

```

| inputlookup mytrackdata.csv

| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"           // apply the model to the entire dataset to predict
                                                                    "x_engineCoolantTemperature"

| eval predicted(x_engineCoolantTemperature) =                    // round the data for display
  round('predicted(x_engineCoolantTemperature)', 2)

| eval residual = 'x_engineCoolantTemperature' -                 // calculate the prediction error
  'predicted(x_engineCoolantTemperature)'

| table "x_engineCoolantTemperature",                             // format the data for a table
  "predicted(x_engineCoolantTemperature)", residual, "x_batteryVoltage"
  "x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed"
  "x_verticalGForce" "y_vehicleType"
```


Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

4. 실제값, 예측값에 대한 차트

Actual vs. Predicted Line Chart [↗](#)

Sort by: Default Sort



[검색에서 열기](#)

Show SPL


Plot actual vs. predicted values on a line chart [↗](#)

```
| inputlookup mytrackdata.csv
```

```
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
```

```
| table _time, "x_engineCoolantTemperature",  
"predicted(x_engineCoolantTemperature)"
```

Actual vs. Predicted Scatter Chart [↗](#)



[검색에서 열기](#)

Show SPL

Plot actual vs. predicted values on a scatter chart [↗](#)

```
| inputlookup mytrackdata.csv
```

```
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
```


```
| table "x_engineCoolantTemperature",  
"predicted(x_engineCoolantTemperature)"
```

Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

5. 잔차(오차)에 대한 차트

Residuals Line Chart [↗](#)



검색에서 열기 [↗](#)

Show SPL


Plot prediction errors on a line chart [↗](#)

```
| inputlookup mytrackdata.csv
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
```

```
| eval residual = 'x_engineCoolantTemperature' -
'predicted(x_engineCoolantTemperature)'
```

```
| table _time, residual
```

Residuals Histogram [↗](#)



검색에서 열기 [↗](#)

Show SPL

Plot prediction errors on a histogram chart [↗](#)

```
| inputlookup mytrackdata.csv
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
```

```
| eval residual = 'x_engineCoolantTemperature' -
'predicted(x_engineCoolantTemperature)'
| `histogram(residual, 100)`
```

```
| rename count as "Sample Count", residual as "Residual Error"
```

Linear regression (선형 회귀)

선형 회귀 모델은 매우 간단하고, 직관적이어서, 머신러닝하면 가장 대표적으로 생각나는 모델

6. 회귀 모델 성능 평가 지표(R^2 , RMSE)

R^2 Statistic [↗](#)

0.3732

Root Mean Squared Error (RMSE) [↗](#)

17.21

검색에서 열기 [↗](#)

Show SPL [↗](#)

Compute R^2 and root mean squared error (RMSE) [↗](#)

```
| inputlookup mytrackdata.csv
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"

| multireport
[ score r2_score "x_engineCoolantTemperature" against
"predicted(x_engineCoolantTemperature)"
| eval rSquared = round(r2_score,4) ]

[ score mean_squared_error "x_engineCoolantTemperature" against
"predicted(x_engineCoolantTemperature)"
| eval RMSE = round(sqrt(mean_squared_error),2) ]

| table RMSE rSquared
| stats first(*) as *
```

Linear regression (선형 회귀)

회귀 모델 성능 평가 지표(MAE, MSE, RMSE, MAPE 등)

새로운 검색

다른 이름으로 저장 ▾

테이블 보기 만들기

닫기

```
| inputlookup mytrackdata.csv
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
| multireport
  [ score r2_score "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval rSquared = round(r2_score,4) ]
  [ score mean_squared_error "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval RMSE = round(sqrt(mean_squared_error),2) ]
  [ score mean_absolute_error "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval MAE = round(mean_absolute_error,2) ]
  [ score explained_variance_score "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  ]
| table mean_squared_error RMSE rSquared MAE explained_variance_score
| stats first(*) as *
```

전체 시간 ▾



⚠ Converting field(s) with categorical values into categorical fields: y_vehicleType

✓ 1개의 결과 (25/06/16 8:41:39.000 이전)

이벤트 샘플링 없음 ▾

작업 ▾



스마트 모드 ▾

이벤트 패턴 **통계 (1)** 시각화

페이지당 20개 ▾

형식

미리보기 ▾

MAE ↕	RMSE ↕	explained_variance_score ↕	mean_squared_error ↕	rSquared ↕
8.44	16.79	0.37567678246417313	282.0463962890475	0.3757

```
| inputlookup mytrackdata.csv
| apply "_exp_draft_f06c615a2f734998bd57f7b96bedea7c"
| multireport
  [ score r2_score "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval rSquared = round(r2_score,4) ]
  [ score mean_squared_error "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval RMSE = round(sqrt(mean_squared_error),2) ]
  [ score mean_absolute_error "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  | eval MAE = round(mean_absolute_error,2) ]
  [ score explained_variance_score "x_engineCoolantTemperature" against "predicted(x_engineCoolantTemperature)"
  ]
| table mean_squared_error RMSE rSquared MAE explained_variance_score
| stats first(*) as *
```

Linear regression (선형 회귀)

7. 회귀 모델 성능 평가 지표(MAE, MSE, RMSE, MAPE 등)

새로운 검색 다른 이름으로 저장 테이블 보기 만들기 닫기

```

| inputlookup mytrackdata.csv
| fit LinearRegression x_engineCoolantTemperature from "x_batteryVoltage" "x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed" "x_verticalGForce" "y_vehicleType" into LR_model
| fit RandomForestRegressor x_engineCoolantTemperature from "x_batteryVoltage" "x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed" "x_verticalGForce" "y_vehicleType" into RFR_model
| fit Lasso x_engineCoolantTemperature from "x_batteryVoltage" "x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed" "x_verticalGForce" "y_vehicleType" into LASSO_model
| fit DecisionTreeRegressor x_engineCoolantTemperature from "x_batteryVoltage" "x_engineSpeed" "x_lateralGForce" "x_longitudeGForce" "x_speed" "x_verticalGForce" "y_vehicleType" into DTR_model
| apply LR_model as LR_prediction
| apply RFR_model as RFR_prediction
| apply LASSO_model as LASSO_prediction
| apply DTR_model as DTR_prediction

| multireport
| [ score r2_score x_engineCoolantTemperature against LR_prediction RFR_prediction LASSO_prediction DTR_prediction ]
| [ score mean_squared_error x_engineCoolantTemperature against LR_prediction RFR_prediction LASSO_prediction DTR_prediction ]
| [ eval RMSE = round(sqrt(mean_squared_error),2) ]
| [ score mean_absolute_error x_engineCoolantTemperature against LR_prediction RFR_prediction LASSO_prediction DTR_prediction ]
| [ score explained_variance_score x_engineCoolantTemperature against LR_prediction RFR_prediction LASSO_prediction DTR_prediction ]
| fields - x_*, y_*, LR_prediction RFR_prediction LASSO_prediction DTR_prediction, _time, predicted(x_engineCoolantTemperature)
  
```

⚠ Converting field(s) with categorical values into categorical fields: y_vehicleType


✓ 16개의 결과 (25/06/16 9:13:13.000 이전) 이벤트 샘플링 없음

이벤트 패턴 통계 (16) 시각화


페이지당 20개 ▾ 형식 미리보기 ▾

Actual field	Predicted field	RMSE	explained_variance_score	mean_absolute_error	mean_squared_error	r2_score
x_engineCoolantTemperature	LR_prediction					0.3760733839496002
x_engineCoolantTemperature	RFR_prediction					0.9156004852625159
x_engineCoolantTemperature	LASSO_prediction					0.33372659649864067
x_engineCoolantTemperature	DTR_prediction					0.9995308063686275
x_engineCoolantTemperature	LR_prediction	16.79			281.8668319929431	
x_engineCoolantTemperature	RFR_prediction	6.17			38.12856068136491	
x_engineCoolantTemperature	LASSO_prediction	17.35			300.9975350545293	
x_engineCoolantTemperature	DTR_prediction	0.46			0.21196422634351997	
x_engineCoolantTemperature	LR_prediction			8.40951813210674		
x_engineCoolantTemperature	RFR_prediction			2.698396352881871		
x_engineCoolantTemperature	LASSO_prediction			9.575726409054841		
x_engineCoolantTemperature	DTR_prediction			0.29849731341729047		
x_engineCoolantTemperature	LR_prediction		0.3760733839496001			
x_engineCoolantTemperature	RFR_prediction		0.9156009028380565			
x_engineCoolantTemperature	LASSO_prediction		0.33372659649864067			
x_engineCoolantTemperature	DTR_prediction		0.9995308063686275			

Clustering (군집) 모델 만들기



여기!



Clustering (군집) - 비지도 학습

- 데이터를 비슷한 그룹(클러스터)으로 자동으로 분류하는 비지도 학습(unsupervised learning) 기법
- 군집 내 데이터들은 서로 비슷하고, 군집 간 데이터들은 서로 다르도록 그룹화하는 것이 목적

The screenshot displays the Splunk Machine Learning Toolkit interface. The top navigation bar includes 'Showcase', 'Experiments' (highlighted with a pink box), 'Search', 'Models', 'Settings', 'Docs', and 'Video Tutorials'. Below the navigation bar, the 'Experiments' section shows a grid of experiment cards. The 'Smart Clustering' card is highlighted with a pink box and a pink circle with the number '1'. A pink circle with the number '2' is next to the 'Create New Experiment' button. A red arrow points from this button to the 'Create New Experiment' dialog box. The dialog box has a title bar 'Create New Experiment' and a close button. It contains three fields: 'Experiment Type' (set to 'Smart Clustering'), 'Experiment Title' (set to 'mytrack_clustering' and highlighted with a pink box), and 'Description' (set to 'Optional'). At the bottom right of the dialog are 'Cancel' and 'Create' buttons, with the 'Create' button highlighted with a pink box and a pink circle with the number '3'.

Experiments

Smart Forecasting 1

Smart Outlier Detection 3

Smart Clustering 2

Smart Prediction 4

Predict Numeric Fields 0

Predict Categorical Fields 5

Detect Numeric Outliers 3

Detect Categorical Outliers 0

Forecast Time Series 1

Cluster Numeric Events 0

Create New Experiment

Create New Experiment

Experiment Type Smart Clustering

Experiment Title mytrack_clustering

Description Optional

Cancel Create

Clustering (군집) - 비지도 학습

- 데이터를 비슷한 그룹(클러스터)으로 자동으로 분류하는 비지도 학습(unsupervised learning) 기법
- 군집 내 데이터들은 서로 비슷하고, 군집 간 데이터들은 서로 다르도록 그룹화하는 것이 목적

1. 데이터 입력하기

| inputlookup mytrackdata.csv

Define Data Source

Search Datasets Metrics

|inputlookup mytrackdata.csv|

✓ 6,000 results (1/1/70 9:00:00.000 AM to 4/24/24 3:16:44.000 PM)

Data Preview Visualization

20 Per Page ▼

x_batteryVoltage ↕	x_engineCoolantTemperature ↕	x_engineSpeed ↕
13.828	79.0	4326
13.855	86.0	4913
13.827	93.0	6542
13.884	86.0	5961
13.657	90.0	2618
14.002	2.0	5827



2. StandardScaler 전처리 적용하기

Learn Data

> Initial data - Search

▼ StandardScaler

Fields to preprocess ?

x_batteryVoltage, x_engineCo... (7) ▼

filter

Select All Clear All

- ☒ x_batteryVoltage
- ☒ x_engineCoolantTemperature
- ☒ x_engineSpeed
- ☒ x_lateralGForce
- ☒ x_longitudeGForce
- ☒ x_speed
- ☒ x_verticalGForce
- ☐ y_vehicleType

Standardize fields ?

- ☒ With respect to mean
- ☒ With respect to standard deviation


Cancel Preprocess

모든 x_* 피쳐 선택하기

Clustering (군집) - 비지도 학습

- 데이터를 비슷한 그룹(클러스터)으로 자동으로 분류하는 비지도 학습(unsupervised learning) 기법
- 군집 내 데이터들은 서로 비슷하고, 군집 간 데이터들은 서로 다르도록 그룹화하는 것이 목적

3. 차원(dimensionality)을 줄이기 위해 PCA 적용



Learn Data

- > Initial data - Search
- > StandardScaler
- ▼ PCA

Fields to preprocess ?

SS_x_batteryVoltage, SS_x_en... (7) ▼

filter

Select All Clear All

- ☒ SS_x_batteryVoltage
- ☒ SS_x_engineCoolantTemperature
- ☒ SS_x_engineSpeed
- ☒ SS_x_lateralGForce
- ☒ SS_x_longitudeGForce
- ☒ SS_x_speed
- ☒ SS_x_verticalGForce
- ☐ x_batteryVoltage
- ☐ x_engineCoolantTemperature
- ☐ x_engineSpeed

Number of new fields to create ?


3

Cancel Preprocess

+ Add preprocessing step ▼

> Cluster Events

4. clustering 시작하기



Learn Data

- > Initial data - Search
- > StandardScaler
- > PCA
- + Add preprocessing step ▼
- ▼ Cluster Events

Fields to cluster

PC_1, PC_2, PC_3 (3) ▼

filter

Select All Clear All

- ☒ PC_1
- ☒ PC_2
- ☒ PC_3
- ☐ SS_x_batteryVoltage
- ☐ SS_x_engineCoolantTemperature
- ☐ SS_x_engineSpeed
- ☐ SS_x_lateralGForce
- ☐ SS_x_longitudeGForce

Number of clusters ?

6

Notes


(optional)

Cancel Find Clusters

Clustering (군집) - 비지도 학습

- 데이터를 비슷한 그룹(클러스터)으로 자동으로 분류하는 비지도 학습(unsupervised learning) 기법
- 군집 내 데이터들은 서로 비슷하고, 군집 간 데이터들은 서로 다르도록 그룹화하는 것이 목적

5. clustering 결과 - 3D



Thank you!